

REPORTE DE LABORATORIO: ANÁLISIS DE SEÑALES DE VOZ EN EL DOMINIO DEL TIEMPO Y DE LA FRECUENCIA PARA RECONOCIMIENTO BIOMÉTRICO

Portada

Título del Proyecto: Estudio Experimental del Contenido Espectral, Temporal y Estadístico de la Voz Humana para Sistemas de Reconocimiento y Biometría de Audio

Institución / Curso: Procesamiento Digital de Señales (DSP) & Sistemas Inteligentes Embebidos

Estudiante / Integrante: Omar Pérez

Plataforma de Adquisición y Hardware: Micrófono Digital MEMS I2S INMP441 + Microcontrolador ESP32-S3 (240 MHz, Xtensa LX7)

Entorno de Análisis: Python (NumPy, SciPy, Matplotlib, Pandas, Jupyter Notebooks)

Repositorio Oficial: <https://github.com/opyntorr/esp32-voice-recognizer.git>

Palabra / Frase Clave de Prueba: "FORWARD"

Fecha: Septiembre 2026

1. Introducción y Marco Teórico

El reconocimiento de voz y la autenticación biométrica de hablante descansan sobre el principio físico de que el tracto vocal de cada ser humano actúa como un filtro acústico con resonancias particulares (denominadas **formantes** $F_1, F_2, F_3, \dots$) y una frecuencia de vibración glotal primaria (tono fundamental F_0 o *pitch*).

Para determinar si las representaciones en el dominio del tiempo y de la frecuencia permiten discriminar un hablante legítimo de impostores y fuentes de ruido, se plantearon tres experimentos secuenciales: 1. **Experimento 1:** Caracterización temporal, espectral, estadística descriptiva completa y validación del Teorema de Wiener-Khinchin mediante la función de autocorrelación. 2. **Experimento 2:** Estudio de repetibilidad sobre un conjunto de repeticiones de voz propia, seleccionando las 50 muestras de mayor consistencia espectral para construir y analizar una **Señal Promedio**. 3. **Experimento 3:** Comparación multidimensional contra hablantes externos (impostores del benchmark internacional *Google Speech Commands v2*) pronunciando exactamente la misma palabra clave, complementado con el análisis del impacto de un canal remoto de comunicación (Zoom / Telefonía pasabanda 300 – 3400 Hz).

2. Experimento 1: Análisis Temporal, Espectral, Estadístico y Autocorrelación

2.1. Adquisición y Representación Temporal y Frecuencial

Se utilizó una muestra representativa de voz propia pronunciando la palabra clave "*FORWARD*", adquirida a una tasa de muestreo de $f_s = 16,000$ Hz con cuantización lineal de 16 bits en escala $[-1.0, 1.0]$ V.

```
Muestra analizada: dataset_processed/target_user/target_00014.wav
Duración: 1.00 segundo (16,000 muestras)
Frecuencia de muestreo: 16,000 Hz
Amplitud pico registrada: 0.9500 V (tras normalización al 95%)
```

Al calcular la Transformada Rápida de Fourier (FFT) centrada con `fftshift`: * El contenido espectral principal de la voz propia se localiza entre **150 Hz y 3,500 Hz**. * Se aprecian picos prominentes de formantes en la vocal 'O' (alrededor de 450 Hz y 1,100 Hz) y componentes de alta frecuencia (3,500 Hz – 7,200 Hz) asociados al sonido sibilante/fricativo de la consonante 'F'.

2.2. Caracterización Estadística en el Dominio del Tiempo

A continuación se presenta la tabla estadística de la señal de voz propia:

Parámetro Estadístico	Expresión Matemática	Valor Numérico	Interpretación Física
Media (μ)	$\frac{1}{N} \sum x[n]$	$-4.619 \times 10^{-6} \text{ V}$	Nivel DC nulo; la señal está perfectamente equilibrada en reposo.
Varianza (σ^2)	$\frac{1}{N} \sum (x[n] - \mu)^2$	$5.398 \times 10^{-3} \text{ V}^2$	Potencia media de la componente alterna de la voz.
Desviación Estándar (σ)	σ^2		
c-2.7,0,-7.17,-2.7,-13.5,-8c-5.8,-5.3,-9.5,-10,-9.5,-14			
c0,-2,0.3,-3.3,1,-4c1.3,-2.7,23.83,-20.7,67.5,-54			
c44.2,-33.3,65.8,-50.3,66.5,-51c1.3,-1.3,3,-2,5,-2c4.7,0,8.7,3.3,12,10			
s173,378,173,378c0.7,0,35.3,-71,104,-213c68.7,-142,137.5,-285,206.5,-429			
c69,-144,104.5,-217.7,106.5,-221			
l0 -0			
c5.3,-9.3,12,-14,20,-14			
H400000v40H845.2724			
s-225.272,467,-225.272,467s-235,486,-235,486c-2.7,4.7,-9.7,-19.7			
c-6,0,-10,-1,-12,-3s-194,-422,-194,-422s-65,47,-65,47z			
M834 80h400000v40h-400000z"/>	0.073473 V	Dispersión efectiva de la amplitud acústica.	
Valor Eficaz (RMS)	$\frac{1}{N} \sum x[n]^2$		
l0 -0			
c4,-6.7,10,-10,18,-10 H400000v40			
H1013.1s-83.4,268,-264.1,840c-180.7,572,-277,876.3,-289,913c-4.7,4.7,-12.7,7,-24,7			
s-12,0,-12,0c-1.3,-3.3,-3.7,-11.7,-7,-25c-35.3,-125.3,-106.7,-373.3,-214,-744			

Parámetro Estadístico	Expresión Matemática	Valor Numérico	Interpretación Física
c-10,12,-21,25,-33,39s-32,39,-32,39c-6,-5.3,-15,-14,-27,-26s25,-30,25,-30			
c26.7,-32.7,52,-63,76,-91s52,-60,52,-60s208,722,208,722			
c56,-175.3,126.3,-397.3,211,-666c84.7,-268.7,153.8,-488.2,207.5,-658.5			
c53.7,-170.3,84.5,-266.8,92.5,-289.5z			
M1001 80h400000v40h-400000z"/>	0.073473 V	Energía total normalizada de la emisión vocal de 1 segundo.	
Pico a Pico (V_{p-p})	$\max(x) - \min(x)$	1.761743 V	Excursión dinámica máxima utilizada del convertidor A/D.
Asimetría (Skewness)	$\frac{E[(x-\mu)^3]}{\sigma^3}$	-0.0211	Prácticamente cero; simetría equilibrada de presión y descompresión.
Curtosis (Kurtosis)	$\frac{E[(x-\mu)^4]}{\sigma^4} - 3$	+11.8492	Distribución marcadamente leptocúrtica (colas pesadas debido a ráfagas fonéticas intensas separadas por pausas de silencio).
Dispersión (σ^2/σ)	σ	0.073473	Razón de varianza sobre desviación estándar.

2.3. Función de Autocorrelación Temporal $R_{xx}(\tau)$

Se calculó la autocorrelación de la señal mediante:

$$R_{xx}[\tau] = \sum_{n=-\infty}^{\infty} x[n] \cdot x[n + \tau]$$

- **Lag Cero ($\tau = 0$):** Presenta el pico máximo global, que representa la energía total de la señal ($R_{xx}(0) = \sum x[n]^2$).
- **Periodicidad del Tono Fundamental (F_0):** Al hacer zoom en el rango de 0 a 30 ms, se observa un pico secundario claro en $\tau \approx 8.125$ ms, correspondiente a un tono fundamental de:

$$F_0 = \frac{1}{\tau} = \frac{1}{0.008125 \text{ s}} \approx 123.1 \text{ Hz}$$

Este valor coincide con el rango fisiológico de la voz masculina adulta en registro modal.

2.4. Teorema de Wiener-Khinchin

El Teorema de Wiener-Khinchin establece formalmente que para una señal de energía o potencia finita, la Transformada de Fourier de su función de autocorrelación equivale exactamente a la Densidad Espectral de Potencia (PSD):

$$\mathcal{F}\{R_{xx}(\tau)\} = |X(f)|^2$$

- **Similitudes:** La gráfica de $\mathcal{F}\{R_{xx}(\tau)\}$ reconstruye idénticamente el perfil de los lóbulos principales y secundarios de $|X(f)|^2$, demostrando que la autocorrelación conserva toda la información de potencia armónica de la voz eliminando únicamente la fase temporal instantánea.
- **Diferencias:** En una implementación numérica discreta finita con relleno de ceros (*zero-padding*), la FFT de la autocorrelación contiene el doble de muestras ($2N - 1 = 31,999$ puntos), ofreciendo una interpolación espectral más suave de la envolvente espectral.

3. Experimento 2: Análisis de Repetibilidad (50 Muestras Más Similares) y Señal Promedio

3.1. Selección Algorítmica de las 50 Muestras Más Consistentes

El usuario grabó más de 148 repeticiones de la palabra clave "FORWARD". Debido a micro-variaciones biomecánicas (ritmo al hablar, estado de ánimo o cansancio), algunas muestras difieren ligeramente.

Para seleccionar de manera objetiva y rigurosa las **50 muestras más parecidas entre sí**, se procedió con un criterio de correlación cruzada espectral: 1. Para cada una de las 148 muestras se calculó su vector de magnitud de Fourier unitario $\hat{S}_k(f) = |X_k(f)| / \|X_k(f)\|_2$. 2. Se construyó la matriz de similitud de Gram $\{\hat{S}_i \cdot \hat{S}_j\} = \hat{S}_i^T \cdot \hat{S}_j$. 3. Se calculó la coherencia media de cada muestra con el resto del corpus. 4. Se seleccionaron los 50 índices con mayor similitud media (promedio de coherencia: **0.7078**).

3.2. Construcción de la Señal Promedio

Se computó la señal promedio temporal:

$$\bar{x}[n] = \frac{1}{50} \sum_{k=1}^{50} x_k[n]$$

3.3. Comparación Estadística: Muestra Individual vs. Señal Promedio

Parámetro	Muestra Individual 1	Señal Promedio (50 Muestras)	Variación Relativa	Discusión Técnica
Media	$-4.619 \times 10^{-6} \text{ V}$	$+1.428 \times 10^{-6} \text{ V}$	≈ 0	Ambas señales mantienen equilibrio nulo en DC.
Varianza (σ^2)	$5.398 \times 10^{-3} \text{ V}^2$	$1.842 \times 10^{-3} \text{ V}^2$	-65.9%	Reducción drástica por cancelación de componentes aleatorias.
Desviación Estándar (σ)	0.073473 V	0.042918 V	-41.6%	Concentración más estrecha alrededor del valor medio.
RMS	0.073473 V	0.042918 V	-41.6%	Disminución debida a pequeños desfases articulatorios naturales.
Asimetría	-0.0211	-0.0452	Mínima	Se preserva la morfología de la forma de onda glotal.
Curtosis en Exceso	+11.8492	+18.9140	+59.6%	Mayor agudeza (<i>peakedness</i>): los silencios se purifican y el pico fonético resalta.
Dispersión (σ^2/σ)	0.073473	0.042918	-41.6%	Menor variabilidad residual.

3.4. Análisis en el Dominio de la Frecuencia

- **Filtrado de Ruido Estocástico Incoherente:** El promediado temporal actúa como un filtro pasabajas estocástico; el ruido de fondo incoherente se reduce en un factor de $1/\sqrt{50} \approx 0.1414$ (~17 dB de mejora en la relación señal a ruido SNR).
- **Definición de Formantes:** En el espectro de la señal promedio, los valles entre formantes se profundizan notablemente y las bandas de resonancia ($F_1 \approx 480 \text{ Hz}$, $F_2 \approx 1,220 \text{ Hz}$, $F_3 \approx 2,450 \text{ Hz}$) quedan perfectamente delineadas, creando una plantilla acústica de referencia (*template*) óptima para el usuario.

4. Experimento 3: Comparativa Multiclase y Efecto del Canal Remoto (Zoom/Teléfono)

4.1. Comparación con Muestras de Impostores (Otras Voces)

Se comparó la voz del usuario legítimo contra grabaciones de personas externas diciendo la misma palabra "FORWARD" (obtenidas del dataset estandarizado *Google Speech Commands v2*):

Hallazgos en el Dominio del Tiempo:

- La envolvente temporal de amplitud y la duración relativa de cada fonema varían sustancialmente: el usuario legítimo mantiene una cadencia de ataque rápida (consonante 'F' en ~120 ms seguida de vocalización sostenida), mientras que los impostores presentan duraciones de vocalización que oscilan entre 280 ms y 650 ms.

Hallazgos en el Dominio de la Frecuencia:

- Tono Fundamental (F_0):**
 - Usuario Legítimo: $F_0 \approx 123.1$ Hz (voz masculina barítono).
 - Impostor 1: $F_0 \approx 98.4$ Hz (voz masculina más grave).
 - Impostor 2: $F_0 \approx 210.5$ Hz (voz femenina/aguda).
- Posición de Formantes:** Las frecuencias de resonancia del tracto vocal presentan desplazamientos superiores a 250 Hz entre personas. Estas diferencias son el fundamento bioacústico que permite la separación de clases.

4.2. Impacto de una Muestra Remota (Zoom / Telefonía Celular Pasabanda)

Se simuló la captura de la voz del usuario transmitida por una plataforma como Zoom o telefonía celular, aplicando el estándar ITU-T G.712 (filtro pasabanda Butterworth de orden 4 entre **300 Hz y 3,400 Hz**) junto con compresión dinámica de códec:

Parámetro	Voz Local Directa (16 kHz)	Voz Remota (Canal 300 - 3400 Hz)	Impacto Físico y Biométrico
Ancho de Banda	0 – 8,000 Hz	300 – 3,400 Hz	Pérdida total de armónicos graves (<300 Hz) y de formantes superiores (>3.4 kHz).
Energía Fricativa ('F')	Completamente audible (3.5 – 7.5 kHz)	Severamente atenuada	Dificulta la discriminación de consonantes fricativas.
Desviación Estándar (σ)	0.073473 V	0.052140 V	Disminución de amplitud por corte de banda.
Curtosis	+11.8492	+8.2150	La compresión de códec reduce los picos extremos de energía.

4.3. Discusión y Propuesta para la Detección Robusta de Voz

- ¿Por qué la amplitud cruda temporal falla para reconocimiento?** La forma de onda en el tiempo cambia drásticamente si el usuario habla un poco más fuerte o a diferente distancia.
- Enfoque Propuesto:**

- Extraer **Coefficientes Cepstrales en la Escala Mel (MFCC)**: Convierten la señal al dominio de la frecuencia mediante FFT, filtran con 40 bancos triangulares Mel (modelando el oído humano) y aplican la Transformada Discreta del Coseno (DCT-II).
- Aplicar **Normalización de Media y Varianza Cepstral (CMVN)**: Resta la media temporal de cada coeficiente, eliminando la coloración del canal de transmisión (neutralizando en gran medida el efecto de micrófonos distintos o llamadas de Zoom).
- Clasificar con una **Red Neuronal Convolucional Profunda (CNN)**: Capaz de aprender relaciones espaciales invariantes en la matriz tiempo-frecuencia.

5. Cuadernos de Jupyter Generados

Como parte de este entregable, se generaron y ejecutaron 3 cuadernos de Jupyter completos con todas las celdas de código, gráficas y tablas de salida incrustadas:

1. [Experimento 1 Analisis Voz.ipynb](#) : Código ejecutable de carga de audio, FFT, histogramas, PDF/CDF empíricas, cálculo de autocorrelación y demostración del Teorema de Wiener-Khinchin.
2. [Experimento 2 Promedio 50 Muestras.ipynb](#) : Selección espectral de las 50 mejores muestras del usuario, promediado síncrono, tabla comparativa de estadísticas y atenuación de ruido.
3. [Experimento 3 Comparativa Voces.ipynb](#) : Comparativa multiclase contra impostores, cálculo de tono fundamental (F_0), simulación del canal telefónico/Zoom (filtro pasabanda 300–3400 Hz) y propuesta biométrica final.

6. Conclusiones Generales

1. **Eficacia del Dominio de la Frecuencia**: Se demostró de manera concluyente que la representación espectral (FFT y densidad espectral) proporciona una base mucho más discriminativa y estable que la señal cruda en el tiempo para distinguir la identidad vocal de diferentes personas.
2. **Autocorrelación como Descriptor Fisiológico**: La función de autocorrelación $R_{xx}(\tau)$ permite aislar con precisión el tono fundamental de las cuerdas vocales (F_0), sirviendo como primer filtro biométrico natural.
3. **Beneficio del Promedio Estadístico**: La señal promedio de 50 repeticiones atenúa el ruido estocástico incoherente en ~ 17 dB, revelando la verdadera envolvente espectral del tracto vocal del usuario.
4. **Vulnerabilidad del Canal Telefónico**: La limitación de banda a 3.4 kHz impuesta por canales de videoconferencia o telefonía elimina formantes cruciales, confirmando la necesidad de algoritmos de normalización de canal como CMVN en sistemas biométricos del mundo real.